

TRƯỜNG
KHOA

BÀI KIỂM TRA THỰC HÀNH
Học kỳ — Năm học 20.....–20.....

LẬP TRÌNH PHÂN TÍCH DỮ LIỆU

Đề số 01 · Phạm vi Buổi 1–5 · Bộ dữ liệu: Chuối cà phê BeanLab

THỜI GIAN LÀM BÀI 60 phút (không kể thời gian phát đề)	TỔNG ĐIỂM 10 điểm — 5 phần, 11 câu	HÌNH THỨC Thực hành trên máy · Jupyter Notebook hoặc Google Colab
THƯ VIỆN ĐƯỢC DÙNG Python chuẩn (re, collections, sqlite3), numpy, pandas, matplotlib, seaborn, scipy, scikit-learn	TÀI LIỆU Được dùng tài liệu cá nhân	KHÔNG ĐƯỢC Dùng Internet, công cụ AI, trao đổi bài

Họ và tên: MSSV: Lớp:

Hướng dẫn làm bài & nộp bài

- Làm bài trong notebook `bai_lam/bai_lam_mau.ipynb`, đổi tên thành `MSSV_HoTen.ipynb`. Mỗi câu làm trong đúng ô được đánh dấu.
- Kết quả phải được in ra trong notebook (bằng `print` hoặc hiển thị bảng). Câu hỏi yêu cầu trả lời bằng lời thì viết vào ô Markdown “Trả lời”.
- Trước khi nộp: chọn **Restart & Run All**. Ô báo lỗi hoặc chưa chạy sẽ không được chấm.
- Nộp 3 tập tin: notebook bài làm, `ca_loi.txt` (câu A1) và `bieu_do.png` (Phần E).

Phân bổ thời gian gợi ý: Phần A 10 phút · Phần B 10 phút · Phần C 17 phút · Phần D 10 phút · Phần E 13 phút.

Buổi	Nội dung được kiểm tra	Câu
1	Python cơ bản · khối lệnh & cấu trúc điều khiển · hàm tự định nghĩa	A1, A2
2	list, tuple, dict, set · mảng & ma trận NumPy · đại số ma trận	A2, B1, B2
3	Tập tin văn bản · tập tin dữ liệu với Pandas · truy cập CSDL · lập trình hướng đối tượng	A1, B3, C1
4	Tiền xử lý: làm sạch dữ liệu · tích hợp dữ liệu · EDA	C2, C3, E
5	Tiền xử lý: biến đổi dữ liệu · thu gọn dữ liệu	D1, D2

Bối cảnh & dữ liệu

BeanLab là chuỗi cà phê có 4 chi nhánh tại TP. Hồ Chí Minh và Hà Nội. Bạn nhận dữ liệu 6 tháng đầu năm 2025 trong thư mục `du_lieu/` gồm 4 tập tin. Dữ liệu là dữ liệu thô, có lỗi — đó là một phần của bài.

Tập tin	Nội dung
---------	----------

nhat_ky_ca_lam.txt	Nhật ký ca làm việc tháng 6/2025 từ máy chấm công, mỗi dòng là một ca của một nhân viên.
giao_dich.csv	Mỗi dòng là một giao dịch. Các cột mô tả ở bảng dưới.
khach_hang.xlsx	Sheet khach_hang : ma_kh, gioi_tinh, nam_sinh, hang_thanh_vien, ngay_dang_ky Sheet hang_thanh_vien : hang_thanh_vien, chiet_khau (tỉ lệ, vd. 0.05 = giảm 5%)
san_pham.db	Cơ sở dữ liệu SQLite, 2 bảng. san_pham : product_id, ten_sp, nhom, gia_ban, gia_ban_vat, gia_von (VNĐ). chi_nhanh : ma_cn, ten_cn, thanh_pho

Cột trong giao_dich.csv	Ý nghĩa
ma_gd	Mã giao dịch, dạng GD + 5 chữ số
thoi_gian	Thời điểm giao dịch, định dạng ngày/tháng/năm giờ:phút (dd/mm/yyyy HH:MM)
ma_cn	Mã chi nhánh CN01–CN04
ma_kh	Mã khách hàng thành viên; để trống nếu là khách vắng lai
ma_sp	Mã sản phẩm
so_luong	Số lượng mua
kenh	Tại quán, Mang đi, Giao hàng
thoi_gian_cho	Thời gian từ lúc đặt đến lúc nhận hàng (phút)
danh_gia	Rất tệ, Tệ, Bình thường, Tốt, Rất tốt; có thể trống

Phần A — Python thuần: tập tin văn bản, regex, hàm

2,0 điểm

Phần này **không dùng pandas và numpy**. Chỉ dùng Python chuẩn: `open`, `re`, `collections` ...
Một dòng hợp lệ trong `nhat_ky_ca_lam.txt` có đúng dạng:

```
2025-06-02 | NV007 | CN01 | ca=SANG | vao=06:58 | ra=11:05
```

- Ngày dạng YYYY-MM-DD; mã nhân viên là NV + đúng 3 chữ số; mã chi nhánh là CN + đúng 2 chữ số.
- Ca là một trong ba giá trị viết hoa: SANG (bắt đầu 07:00), CHIEU (12:00), TOI (17:00).
- Giờ vào và giờ ra dạng HH:MM (2 chữ số giờ, 2 chữ số phút).
- Các trường ngăn cách bởi `|` (khoảng trắng – gạch đứng – khoảng trắng).
- Dòng trống và dòng bắt đầu bằng `#` được bỏ qua — không tính là hợp lệ, cũng không tính là lỗi.

Câu A1. Lọc dòng hợp lệ bằng biểu thức chính quy

1,0 điểm

Đọc tập tin, dùng module `re` phân loại từng dòng thành hợp lệ hoặc không hợp lệ.

1. In số dòng hợp lệ và số dòng không hợp lệ.
2. In số ca của từng loại ca (SANG, CHIEU, TOI) trong các dòng hợp lệ.
3. Ghi toàn bộ dòng không hợp lệ (giữ nguyên nội dung, mỗi dòng một dòng) vào tập tin `ca_loi.txt`.

Câu A2. Thống kê đi trễ

1,0 điểm

Viết hàm `thong_ke_di_tre(cac_dong, tre_cho_phep=5, toi_thieu=10)` nhận danh sách dòng hợp lệ và trả về dict `{mã nhân viên: tỉ lệ đi trễ}`. Một ca bị tính là **đi trễ** khi giờ vào muộn hơn giờ bắt đầu ca **quá** `tre_cho_phep` phút (vào đúng 07:05 ca SANG không tính trễ). Tỉ lệ = số ca đi trễ ÷ tổng số ca của nhân viên đó. Chỉ đưa vào kết quả những nhân viên có ít nhất `toi_thieu` ca.

- Gọi hàm với tham số mặc định, in tỉ lệ của từng nhân viên (3 chữ số thập phân) và cho biết nhân viên có tỉ lệ đi trễ cao nhất.
- Dùng kiểu `set`, liệt kê các nhân viên đã làm việc ở **cả 4 chi nhánh** (xét tất cả dòng hợp lệ).

Phần B — NumPy & lập trình hướng đối tượng

2,0 điểm

Câu B1. Ma trận doanh thu

0,5 điểm

Ma trận `M` (đã có sẵn trong notebook) là doanh thu (triệu đồng) của 4 chi nhánh CN01–CN04 (dòng) trong 7 ngày từ thứ Hai đến Chủ nhật (cột). **Không dùng vòng lặp.**

```
M = np.array([[18.2, 16.5, 17.1, 19.4, 24.8, 31.2, 29.5],
              [11.4, 10.9, 12.2, 12.8, 15.1, 21.7, 20.3],
              [15.6, 14.8, 15.9, 16.4, 20.2, 26.9, 25.1],
              [ 9.8, 10.2,  9.5, 11.1, 13.6, 18.4, 17.2]])
```

- Tổng doanh thu tuần của từng chi nhánh và chi nhánh cao nhất; trung bình theo từng thứ và thứ có trung bình cao nhất.
- Tỉ trọng doanh thu cuối tuần (Thứ Bảy + Chủ nhật) trong tổng tuần của từng chi nhánh — dùng broadcasting.
- Số ô có doanh thu lớn hơn doanh thu trung bình tuần **của chính chi nhánh đó**.

Câu B2. Giải hệ phương trình

0,5 điểm

Ba hoá đơn nhập nguyên liệu gồm cà phê (kg), sữa (lít) và đường (kg), đơn giá chưa biết:

Hoá đơn	Cà phê (kg)	Sữa (lít)	Đường (kg)	Tổng tiền (nghìn đồng)
1	5	10	2	1 470
2	3	12	1	1 069
3	8	6	4	2 052

Lập ma trận hệ số và vector vế phải, dùng `np.linalg.solve` tìm đơn giá mỗi nguyên liệu, rồi kiểm tra lại nghiệm bằng phép nhân ma trận.

Câu B3. Lớp sản phẩm

1,0 điểm

- Lớp `SanPham(ma, ten, gia_ban, gia_von)`: `gia_ban` là **property**; setter ném `ValueError` nếu giá bán thấp hơn giá vốn (áp dụng cả lúc khởi tạo).
- Phương thức `gia_thuc_te()` trả về giá bán; `bien_loi_nhuan()` = (giá thực tế – giá vốn) ÷ giá thực tế; `__str__` trả về chuỗi đúng mẫu `SP04 Latte: 55,000đ · biên LN 67.3%`.

- Lớp con `SanPhamKhuyenMai`(`ma`, `ten`, `gia_ban`, `gia_von`, `giam`) kế thừa `SanPham`, gọi `super().__init__`, ghi đè `gia_thuc_te()` = giá bán $\times$ (1 – giam).

Chạy kiểm thử: `in SanPham('SP04', 'Latte', 55000, 18000)`; `in SanPhamKhuyenMai('SP11', 'Cookie đá xay', 65000, 22000, 0.20)`; gán giá bán Latte thành 15000 trong khối `try/except` và in thông báo lỗi.

Phần C — Pandas: đọc, làm sạch và tích hợp dữ liệu

2,5 điểm

Câu C1. Đọc dữ liệu từ ba loại nguồn

0,5 điểm

- Đọc `giao_dich.csv`; chuyển cột `thoi_gian` sang kiểu `datetime`, chú ý định dạng ngày/tháng/năm giờ:phút.
- Đọc cả hai sheet của `khach_hang.xlsx`.
- Kết nối `san_pham.db` bằng `sqlite3`, đọc hai bảng bằng `pd.read_sql` với câu lệnh SQL.
- In kích thước (shape) của 4 bảng; in số giá trị thiếu của các cột có giá trị thiếu trong bảng giao dịch.

Câu C2. Làm sạch bảng giao dịch

1,0 điểm

Thực hiện **đúng thứ tự** năm bước sau:

1. Loại bỏ các dòng trùng lặp hoàn toàn.
2. Chuẩn hoá `kenh` về đúng 3 giá trị `Tại quán`, `Mang đi`, `Giao hàng`. Lưu ý dữ liệu có cả cách viết không dấu.
3. Loại bỏ giao dịch có `so_luong` lớn hơn 20 (lỗi nhập liệu), các dòng đang trống `so_luong` phải được giữ lại; sau đó điền `so_luong` trống bằng **trung vị theo kênh** và chuyển về kiểu số nguyên.
4. Đổi các giá trị `thoi_gian_cho` âm (lỗi thiết bị) thành giá trị thiếu.
5. Tìm ngoại lai `thoi_gian_cho` theo quy tắc IQR, với Q1, Q3 **tính riêng cho từng kênh** (ngoại lai khi $> Q3 + 1,5 \times IQR$). In số ngoại lai của mỗi kênh, kéo các giá trị đó về đúng ngưỡng trên của kênh (winsorization), rồi điền `thoi_gian_cho` còn trống bằng trung vị theo kênh.

In ra: số dòng sau bước 1 và sau bước 3; số giao dịch theo từng kênh; trung vị `so_luong` theo kênh; số ngoại lai theo kênh.

Câu C3. Tích hợp dữ liệu

1,0 điểm

1. Bảng sản phẩm: đổi tên `product_id` thành `ma_sp` cho khớp lược đồ. Viết code chứng minh `gia_ban_vat` là cột dẫn xuất (= `gia_ban` $\times$ 1,08, sai số làm tròn ≤ 1 đồng) rồi xoá cột này.
2. Bảng khách hàng: in số mã khách bị trùng rồi loại trùng; chuẩn hoá `gioi_tinh` về đúng hai giá trị `Nam`, `Nữ`; ghép sheet `hang_thanh_vien` để mỗi khách có `chiet_khau`.
3. Loại các giao dịch có `ma_sp` không có trong danh mục sản phẩm (in số dòng bị loại). Ghép giao dịch với sản phẩm, khách hàng và chi nhánh sao cho **không mất giao dịch nào** còn lại; giao

dịch không có khách khóp: `hang_thanh_vien = "Văng lai"`, `chiet_khau = 0`. Gọi bảng kết quả là `df`.

4. Tạo `doanh_thu = so_luong × gia_ban × (1 - chiet_khau)` và `loi_nhuan = doanh_thu - so_luong × gia_von`.

In ra: số dòng của `df`; số giao dịch “Văng lai”; tổng doanh thu và tổng lợi nhuận (có dấu phân cách hàng nghìn); doanh thu theo tên chi nhánh (triệu đồng, 1 chữ số thập phân, giảm dần).

Phần D — Biến đổi & thu gọn dữ liệu

1,5 điểm

Dùng bảng `df` đã tạo ở câu C3.

Câu D1. Biến đổi dữ liệu

0,75 điểm

- Mã hoá thứ bậc `danh_gia` thành cột `diem_dg`: Rất tệ 1 · Tệ 2 · Bình thường 3 · Tốt 4 · Rất tốt 5; điền ô trống bằng mode, kiểu số nguyên.
- Tạo cột `log_cho = log(1 + thoi_gian_cho)`; in độ lệch (skewness, `scipy.stats.skew`) của `thoi_gian_cho` trước và sau biến đổi.
- Mã hoá one-hot cột `kenh`; in tên các cột mới.

Câu D2. Thu gọn dữ liệu theo khách hàng

0,75 điểm

- Chỉ xét khách thành viên (bỏ “Văng lai”). Tạo bảng `khach`, mỗi khách một dòng, gồm: `so_gd` (số giao dịch), `tong_chi` (tổng doanh thu, triệu đồng), `sl_tb` (số lượng trung bình), `cho_tb` (thời gian chờ trung bình), `diem_tb` (điểm đánh giá trung bình), `ti_le_giao` (tỉ lệ giao dịch kênh Giao hàng). In kích thước bảng.
- Chia `tong_chi` thành 3 nhóm **cùng số lượng** Thấp / Vừa / Cao; in số khách mỗi nhóm.
- Tính ma trận tương quan 6 cột số; chỉ ra các cặp có $|r| > 0,7$ và giải thích vì sao có thể coi một cột trong mỗi cặp là dư thừa.
- Chuẩn hoá z-score 6 cột số, chạy PCA; in số thành phần ít nhất cần để giữ $\geq 90\%$ phương sai.

Phần E — Trực quan hoá

2,0 điểm

Vẽ **một hình gồm 4 biểu đồ** (2 hàng × 2 cột):

- Trên trái: biểu đồ đường doanh thu theo tháng của **từng kênh** (3 đường), có điểm đánh dấu và chú thích.
- Trên phải: histogram của `log_cho`, tô màu theo kênh.
- Dưới trái: biểu đồ cột chồng doanh thu theo chi nhánh (`ten_cn`), mỗi cột chia theo nhóm sản phẩm.
- Dưới phải: heatmap ma trận tương quan của câu D2, có ghi số trên từng ô, thang màu từ -1 đến 1.

Mỗi biểu đồ có tiêu đề và nhãn cho các trục, ghi rõ đơn vị. Lưu hình thành `bieu_do.png` với độ phân giải 150 dpi. Viết 2 câu nhận xét: (1) xu hướng của kênh Giao hàng; (2) mối liên hệ giữa thời

gian chờ và điểm đánh giá.

— HẾT —

Cán bộ coi thi không giải thích gì thêm.