

LẬP TRÌNH PHÂN TÍCH DỮ LIỆU

Đề số 01 · Bộ dữ liệu: Chuỗi cửa hàng tiện lợi MiniMart

THỜI GIAN LÀM BÀI 60 phút (không kể thời gian phát đề)	TỔNG ĐIỂM 10 điểm – 5 phần, 9 câu
HÌNH THỨC Thực hành trên máy · Jupyter Notebook hoặc Google Colab	THƯ VIỆN ĐƯỢC DÙNG Python chuẩn, <code>numpy</code> , <code>pandas</code> , <code>matplotlib</code> , <code>seaborn</code> , <code>scipy</code>
TÀI LIỆU Được dùng tài liệu cá nhân	KHÔNG ĐƯỢC Dùng Internet, công cụ AI, trao đổi bài

Họ và tên: MSSV: Lớp:

Hướng dẫn làm bài & nộp bài

- Làm bài trong notebook `bai_lam/bai_lam_mau.ipynb`, đổi tên thành `MSSV_HoTen.ipynb`. Mỗi câu làm trong đúng ô được đánh dấu.
- Kết quả phải được **in ra** trong notebook (bằng `print` hoặc hiển thị bảng). Câu hỏi yêu cầu trả lời bằng lời thì viết vào ô Markdown “Trả lời”.
- Trước khi nộp: chọn **Restart & Run All**. Ô báo lỗi hoặc chưa chạy sẽ không được chấm.
- Nộp 3 tập tin: notebook bài làm, `dong_loi.txt` (câu A1) và `bieu_do.png` (Phần D).

Phân bổ thời gian gợi ý: Phần A 12 phút · Phần B 18 phút · Phần C 12 phút · Phần D 8 phút · Phần E 10 phút.

Bối cảnh & dữ liệu

MiniMart là chuỗi cửa hàng tiện lợi hoạt động tại 5 thành phố. Bạn nhận dữ liệu 6 tháng đầu năm 2025 trong thư mục `du_lieu/` gồm 3 tập tin. Dữ liệu là **dữ liệu thô, có lỗi** – đó là một phần của bài.

Tập tin	Nội dung
<code>don_hang.csv</code>	Mỗi dòng là một đơn hàng. Các cột mô tả ở bảng dưới.
<code>khach_hang.xlsx</code>	Sheet <code>khach_hang</code> : <code>ma_kh</code> , <code>gioi_tinh</code> , <code>nam_sinh</code> , <code>hang_thanh_vien</code> , <code>ngay_dang_ky</code> Sheet <code>hang_thanh_vien</code> : <code>hang_thanh_vien</code> , <code>chiet_khau</code> (tỉ lệ, vd. 0.05 = giảm 5%)
<code>nhat_ky_giao_hang.txt</code>	Nhật ký giao hàng tháng 6/2025, mỗi dòng là một lần giao.

Cột trong <code>don_hang.csv</code>	Ý nghĩa
<code>ma_don</code>	Mã đơn hàng, dạng DH + 5 chữ số
<code>ngay_dat</code>	Ngày đặt hàng, định dạng ngày/tháng/năm (dd/mm/yyyy)
<code>ma_kh</code>	Mã khách hàng; để trống nếu là khách vắng lai
<code>thanh_pho</code>	Thành phố của cửa hàng
<code>danh_muc</code>	Đồ uống, Thực phẩm, Gia dụng, Mỹ phẩm, Văn phòng phẩm
<code>don_gia</code>	Đơn giá (VNĐ)

Cột trong don_hang.csv	Ý nghĩa
so_luong	Số lượng mua
phuong_thuc_tt	Tiền mặt, Chuyển khoản, Ví điện tử
danh_gia	Điểm đánh giá của khách, 1-5; có thể trống

Phần A — Python thuần: xử lý tập tin văn bản

2,0 điểm

Phần này **không dùng pandas**. Chỉ dùng Python chuẩn: `open`, `re`, `collections` ...

Một dòng **hợp lệ** trong `nhat_ky_giao_hang.txt` có đúng dạng:

```
2025-06-01 07:37 | DH02295 | GIAO_THANH_CONG | shipper=SP07
```

- Ngày giờ dạng `YYYY-MM-DD HH:MM`; mã đơn là `DH` + **đúng 5** chữ số; mã shipper là `SP` + **đúng 2** chữ số.
- Trạng thái là một trong ba giá trị: `GIAO_THANH_CONG`, `THAT_BAI`, `HOAN_TRA`.
- Các trường ngăn cách bởi `|` (khoảng trắng – gạch đứng – khoảng trắng); trường cuối viết `shipper=SPxx`.
- Dòng trống** và dòng **bắt đầu bằng #** được bỏ qua – không tính là hợp lệ, cũng không tính là lỗi.

Câu A1. Lọc dòng hợp lệ bằng biểu thức chính quy

1,0 điểm

Đọc tập tin, dùng module `re` phân loại từng dòng thành hợp lệ hoặc không hợp lệ.

- In số dòng hợp lệ và số dòng không hợp lệ.
- In số lần xuất hiện của từng trạng thái trong các dòng hợp lệ.
- Ghi toàn bộ dòng không hợp lệ (giữ nguyên nội dung, mỗi dòng một dòng) vào tập tin `dong_loi.txt`.

Câu A2. Tỷ lệ giao thành công của từng shipper

1,0 điểm

Viết hàm `ti_le_thanh_cong(cac_dong, toi_thieu=20)` nhận danh sách dòng hợp lệ và trả về **dict** `{mã shipper: tỉ lệ}`, trong đó $\text{tỉ lệ} = \frac{\text{số lần GIAO_THANH_CONG}}{\text{tổng số lần giao của shipper đó}}$. Chỉ đưa vào kết quả những shipper có **ít nhất** `toi_thieu` lần giao.

Gọi hàm với tham số mặc định, in tỉ lệ của từng shipper (3 chữ số thập phân) và cho biết shipper có tỉ lệ thấp nhất.

Phần B — Pandas: đọc, làm sạch và ghép dữ liệu

3,0 điểm

Câu B1. Đọc và khảo sát dữ liệu

0,5 điểm

- Đọc `don_hang.csv` và **cả hai sheet** của `khach_hang.xlsx`.
- Chuyển cột `ngay_dat` sang kiểu `datetime`, chú ý định dạng ngày/tháng/năm.
- In kích thước (`shape`) của bảng đơn hàng và bảng khách hàng; in số giá trị thiếu của **các cột có giá trị thiếu** trong bảng đơn hàng.

Câu B2. Làm sạch bảng đơn hàng

1,5 điểm

Thực hiện **đúng thứ tự** bốn bước sau:

- Loại bỏ các dòng **trùng lặp hoàn toàn**.

2. Chuẩn hoá `thanh_pho`: bỏ khoảng trắng thừa ở hai đầu và viết hoa chữ cái đầu mỗi từ (vd. " hà nội " → "Hà Nội"). Sau bước này cột chỉ còn đúng 5 giá trị.
3. Loại bỏ các đơn có `so_luong` lớn hơn 100 (lỗi nhập liệu). Các dòng đang trống `so_luong` phải được giữ lại.
4. Điền `so_luong` còn trống bằng trung vị `so_luong` của danh mục tương ứng, rồi chuyển cột về kiểu số nguyên.

In ra: số dòng sau bước 1 và sau bước 3; số đơn theo từng thành phố sau bước 2; trung vị `so_luong` theo từng danh mục dùng ở bước 4.

Câu B3. Ghép bảng và tính thành tiền

1,0 điểm

- Ghép hai sheet của `khach_hang.xlsx` để mỗi khách hàng có `chiet_khau`.
- Ghép vào bảng đơn hàng theo `ma_kh` sao cho **không mất đơn hàng nào**. Gọi bảng kết quả là `df`.
- Đơn không có `ma_kh`, hoặc có `ma_kh` không nằm trong danh sách khách hàng: đặt `hang_thanh_vien` = "Văng lai" và `chiet_khau` = 0.
- Tạo cột `thanh_tien` = `so_luong` × `don_gia` × (1 - `chiet_khau`).

In ra: số dòng của `df`, số đơn “Văng lai”, tổng doanh thu (tổng `thanh_tien`, có dấu phân cách hàng nghìn).

Phần C — Phân tích tổng hợp

2,0 điểm

Dùng bảng `df` đã tạo ở câu B3.

Câu C1. Doanh thu theo thành phố và danh mục

1,0 điểm

Lập bảng doanh thu (đơn vị **triệu đồng**, làm tròn 1 chữ số thập phân) có dòng là thành phố, cột là danh mục, kèm **dòng tổng và cột tổng**. Từ bảng, cho biết:

- Thành phố có tổng doanh thu cao nhất.
- Danh mục có doanh thu cao nhất **tại từng thành phố**.

Câu C2. Doanh thu theo tháng

1,0 điểm

Tính doanh thu từng tháng (triệu đồng) và tốc độ tăng trưởng (%) so với tháng liền trước. Tháng nào tăng trưởng mạnh nhất?

Viết 1–2 câu giải thích: vì sao **không nên** kết luận tháng đó là tháng “kinh doanh tốt nhất” chỉ dựa vào tốc độ tăng trưởng.

Phần D — Trực quan hoá

1,5 điểm

Vẽ **một hình** gồm 2 biểu đồ đặt cạnh nhau (1 hàng × 2 cột):

- **Bên trái:** biểu đồ đường thể hiện doanh thu theo tháng (kết quả câu C2), có điểm đánh dấu tại mỗi tháng.
- **Bên phải:** biểu đồ hộp (boxplot) của `thanh_tien` theo `hang_thanh_vien`, sắp theo thứ tự Văng lai → Thường → Bạc → Vàng.
- Mỗi biểu đồ có tiêu đề và nhãn cho cả hai trục, **ghi rõ đơn vị**.
- Lưu hình thành `bieu_do.png` với độ phân giải **150 dpi**.

Viết 1–2 câu nhận xét về biểu đồ hộp.

Phần E — Thống kê suy luận

1,5 điểm

Dùng mức ý nghĩa $\alpha = 0,05$ và module `scipy.stats`.

Câu E1. So sánh giá trị đơn giữa hai hạng thành viên

1,0 điểm

Ban quản lý cho rằng khách hạng **Vàng** có giá trị đơn trung bình (`thanh_tien`) **cao hơn** khách hạng **Thường**.

- Phát biểu giả thuyết H_0 và H_1 .
- Thực hiện kiểm định t hai mẫu độc lập, **một phía, không giả định phương sai bằng nhau** (Welch).
- In trung bình của từng nhóm, thống kê t và p-value; kết luận bằng lời trong bối cảnh bài toán.

Câu E2. Phương thức thanh toán và thành phố

0,5 điểm

Lập bảng chéo `thanh_pho` × `phuong_thuc_tt` và dùng kiểm định **chi-bình phương** để trả lời: phương thức thanh toán có độc lập với thành phố không? In χ^2 , bậc tự do, p-value và nêu kết luận.

– HẾT –

Cán bộ coi thi không giải thích gì thêm.